ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA KHOA HỌC ỨNG DỤNG

BÁO CÁO BÀI TẬP LỚN

XÁC SUẤT VÀ THỐNG KÊ (MT2013)

PHÂN TÍCH VÀ DỰ ĐOÁN TẤN CÔNG MẠNG DỰA TRÊN ĐẶC TRƯNG LƯU LƯỢNG MẠNG

Giảng viên hướng dẫn: Thái Bá Ngọc
Lớp / Nhóm: [Bổ sung]
Sinh viên / MSSV: [Bổ sung danh sách]
Học kỳ – Năm học: [Bổ sung]

Thành phố Hồ Chí Minh, năm 2026

Mục lục

1 Đặt vấn đề **1**

1.1 Bối cảnh và lý do lựa chọn đề tài 1

1.2 Vấn đề nghiên cứu và ý nghĩa thực tiễn 1

1.3 Mục tiêu và câu hỏi nghiên cứu 1

1.4 Phạm vi nghiên cứu và bố cục báo cáo 1

2 Dữ liệu và tiền xử lý **2**

2.1 Nguồn gốc và cách hình thành NSL-KDD 2

2.2 Quy mô, cấu trúc và vai trò các tập dữ liệu 3

2.3 Các đặc trưng mạng, loại biến và ý nghĩa 3

2.4 Hệ thống nhãn và các nhóm hành vi tấn công 4

2.5 Khảo sát chất lượng dữ liệu ban đầu 5

2.6 Các bước làm sạch và chuẩn hóa nhãn 7

2.7 Quy ước bộ dữ liệu dùng cho từng phân tích 8

3 Phương pháp Xác suất và Thống kê **9**

3.1 Thiết kế phân tích và quy ước thống kê chung 9

3.2 Thống kê mô tả và trực quan hóa dữ liệu 9

3.3 Phân tích tương quan Pearson 9

3.4 Ước lượng khoảng tin cậy Wilson cho tỷ lệ 9

3.4.1 Mục đích và tham số 9

3.4.2 Công thức 9

3.4.3 Giả định và điều kiện áp dụng 10

3.4.4 Cách sử dụng trong bộ dữ liệu 10

3.5 Phân tích phương sai một yếu tố và phương án Welch 10

3.5.1 Mục đích và lựa chọn biến 10

3.5.2 Giả thuyết 10

3.5.3 ANOVA cổ điển và kích thước ảnh hưởng 11

3.5.4 Phương án Welch 11

3.5.5 Giả định, chẩn đoán và thang phân tích 11

3.5.6 Lấy mẫu phục vụ biểu đồ 12

3.6 Kiểm định độc lập Chi-square và Cramér's V 12
3.7 Hồi quy Logistic nhị phân và đánh giá mô hình 12

4 Kết quả và thảo luận 13
4.1 Kết quả thống kê mô tả 13
4.2 Phân bố nhãn và so sánh đặc trưng Normal/Attack 14
4.3 Kết quả phân tích tương quan Pearson 17
4.4 Kết quả khoảng tin cậy 95% cho năm nhóm 17
4.5 Kết quả ANOVA, kiểm tra giả định và hậu kiểm 18
4.5.1 Thống kê mô tả và kiểm tra giả định 18
4.5.2 Kết quả kiểm định tổng thể và kích thước ảnh hưởng 20
4.5.3 Hậu kiểm Games–Howell và trả lời câu hỏi nghiên cứu 21
4.6 Kết quả kiểm định Chi-square và mức độ liên hệ 23
4.7 Kết quả huấn luyện và đánh giá hồi quy Logistic 24
4.8 Tổng hợp và đối chiếu các phát hiện 24
4.9 Hạn chế dữ liệu, phương pháp và khả năng khái quát 24

5 Kết luận và kiến nghị 25
5.1 Kết luận theo từng câu hỏi nghiên cứu 25
5.2 Kiến nghị và hướng phát triển 25

A Phân công và đóng góp của các thành viên 27

Danh mục hình

4.1 Tỷ lệ Normal và bốn nhóm tấn công trên KDDTrain+ ($n = 125.973$). Trục tung tuyến tính; giá trị ghi trên cột giúp nhận biết hai nhóm hiếm. . 15

4.2 Histogram so sánh trên KDDTrain+: mỗi nhóm được chuẩn hóa riêng để tổng chiều cao các khoảng bằng 100%; dùng cùng 40 khoảng chia đều cho hai nhóm ở từng ô. `src_bytes` chỉ đổi thang trực quan thành $\ln(1 + x/\text{byte})$; hai biến còn lại giữ thang gốc. Không cắt miền giá trị. . . 16

4.3 Boxplot theo nhãn trên KDDTrain+. Hộp biểu diễn Q_1–Q_3, đường giữa là trung vị; râu tới quan sát xa nhất còn trong ngưỡng $1{,}5\,IQR$ trên thang vẽ; các điểm ngoài râu vẫn được hiển thị. Chỉ `src_bytes` dùng $\ln(1 + x/\text{byte})$, giữ toàn bộ miền. 17

4.4 Ước lượng điểm và khoảng tin cậy Wilson 95% cho năm nhóm. Trục tỷ lệ dùng thang logarit để khoảng của R2L và U2R vẫn quan sát được; kích thước mẫu được ghi cạnh mỗi điểm. 18

4.5 ECDF theo năm nhóm. `src_bytes` và `duration` dùng $\ln(1+x)$; lấy mẫu cố định tối đa 5.000 quan sát/nhóm chỉ để vẽ theo quy trình ở Mục 3.5. Mọi kiểm định sử dụng toàn bộ dữ liệu. 20

4.6 Q–Q plot của $\log(1 + \texttt{src_bytes})$ và $\log(1 + \texttt{duration})$, dùng tối đa 1.000 quan sát/nhóm. Các điểm lệch đường tham chiếu cho thấy phép log giảm nhưng không loại bỏ hoàn toàn sai lệch chuẩn. 20

4.7 P-value Games–Howell đã hiệu chỉnh trong 10 so sánh cặp của từng RQ. Dấu * biểu thị $p_{adj} < 0{,}05$; ô không có dấu * không được diễn giải là hai trung bình bằng nhau, mà chỉ là chưa đủ bằng chứng khác biệt với dữ liệu hiện có. 22

4.8 Tỷ lệ `duration`=0 và khoảng tin cậy Wilson 95% theo nhóm. Đây là phần nhị phân của phân tích hai phần, không phải khoảng tin cậy của thời lượng trung bình. 23

Danh mục bảng

2.1 Quy mô và vai trò các tệp NSL-KDD được sử dụng 3
2.2 Các nhóm đặc trưng theo nội dung đo lường 4
2.3 Một nhóm bình thường và bốn nhóm tấn công 5
2.4 Kiểm tra cấu trúc và chất lượng của hai tập dữ liệu gốc 6
2.5 Đối chiếu dữ liệu trước và sau chuẩn hóa nhãn 7

4.1 Xu hướng trung tâm và độ phân tán trên KDDTrain+ ($n = 125.973$ cho mỗi biến) 13
4.2 Phân vị, phương sai mẫu và tỷ lệ bằng 0 trên KDDTrain+ 14
4.3 Phân bố năm nhóm và tổng hợp nhị phân trên KDDTrain+ 15
4.4 So sánh trực tiếp Normal và Attack trên KDDTrain+ 16
4.5 Ước lượng tỷ lệ và khoảng tin cậy Wilson 95% trên KDDTrain+ 17
4.6 Trung bình và trung vị theo nhóm trên thang gốc 19
4.7 Kiểm tra giả định trên thang dùng cho kiểm định chính 19
4.8 Kết quả Welch ANOVA cho bốn câu hỏi nghiên cứu 21
4.9 Tóm tắt hậu kiểm Games–Howell trong từng câu hỏi 21

Chương 1

Đặt vấn đề

1.1 Bối cảnh và lý do lựa chọn đề tài

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

1.2 Vấn đề nghiên cứu và ý nghĩa thực tiễn

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

1.3 Mục tiêu và câu hỏi nghiên cứu

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

1.4 Phạm vi nghiên cứu và bố cục báo cáo

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

Chương 2

Dữ liệu và tiền xử lý

2.1 Nguồn gốc và cách hình thành NSL-KDD

Hệ thống phát hiện xâm nhập (Intrusion Detection System, IDS) phân tích dấu hiệu hoạt động để nhận biết các hành vi có khả năng xâm phạm hệ thống. Trong bài toán dữ liệu mạng, bản ghi kết nối là đơn vị quan sát: nó tóm tắt một kết nối cùng các thống kê liên quan, không phải một gói tin riêng lẻ. Các đặc trưng này cho phép mô tả phân bố và so sánh hành vi theo nhãn [3].

NSL-KDD có nguồn gốc từ một chuỗi xử lý dữ liệu lịch sử. Chương trình DARPA 1998 do MIT Lincoln Laboratory tổ chức sử dụng lưu lượng và nhật ký thu trong mạng mô phỏng để đánh giá IDS [6]. KDD Cup 1999 sử dụng dữ liệu phát triển từ chương trình này, chuyển lưu lượng thô thành các bản ghi kết nối có đặc trưng và nhãn [3]. Năm 2009, Tavallaee và cộng sự đề xuất NSL-KDD bằng cách tuyển chọn các bản ghi của KDD'99; đây không phải một đợt thu lưu lượng mạng mới [1].

Hai vấn đề được xử lý khi xây dựng NSL-KDD là sự lặp lại nhiều bản ghi và việc mẫu quá dễ làm giảm khả năng phân biệt giữa các phương pháp. Sau bước loại lặp, tác giả dùng bảy thuật toán, mỗi thuật toán học trên ba mẫu, tạo 21 bộ phân loại. Số bộ dự đoán đúng một bản ghi được dùng để phân tầng mức độ dễ/khó; việc chọn mẫu giảm ưu thế của tầng dễ vốn chiếm tỷ trọng lớn [1]. Vì vậy, trường độ khó không đo mức nghiêm trọng của một cuộc tấn công. Tính duy nhất của các bản ghi được kiểm tra theo từng định nghĩa cụ thể tại mục khảo sát chất lượng dữ liệu.

Nguồn gốc mô phỏng và thời điểm lịch sử giới hạn khả năng khái quát. UNB lưu ý NSL-KDD chưa đại diện hoàn hảo cho mạng thực [2]. Do đó, bộ dữ liệu phù hợp cho minh họa phương pháp thống kê và so sánh mô hình trong một chuẩn thử nghiệm xác định; các tỷ lệ và kết quả trong bài không được xem là tình hình tấn công Internet hiện tại hay hiệu quả IDS khi triển khai. Các tập sử dụng được mô tả tiếp theo.

2.2 Quy mô, cấu trúc và vai trò các tập dữ liệu

Hai tệp TXT đầy đủ, `KDDTrain+.txt` và `KDDTest+.txt`, là nguồn bản ghi chính. Chúng có định dạng phân cách bằng dấu phẩy, không có dòng tiêu đề. Bảng 2.1 ghi kết quả kiểm kê trực tiếp; các bản 20% của Train và Test loại mức khó 21 có trong gói dữ liệu nhưng không được dùng thay thế cho hai tập đầy đủ.

Bảng 2.1: Quy mô và vai trò các tệp NSL-KDD được sử dụng

Tập	Tệp / định dạng	Dòng	Trường	Vai trò
train	`KDDTrain+.txt`	125.973	43	Dữ liệu chính cho mô tả và phát triển mô hình
train	`KDDTrain+.arff`	125.973	42	Đối chiếu schema và nhãn nhị phân
test	`KDDTest+.txt`	22.544	43	Đánh giá dự đoán độc lập
test	`KDDTest+.arff`	22.544	42	Đối chiếu schema và nhãn nhị phân

Mỗi dòng TXT gồm 41 đặc trưng mạng theo thứ tự schema, một tên nhãn gốc (`attack_name`) và một trường độ khó (`difficulty`), tổng cộng 43 trường. Độ khó là số bộ phân loại dự đoán đúng trong quá trình xây dựng dữ liệu, có thang 0–21; giá trị cao biểu thị dễ hơn đối với các bộ phân loại đó [2]. Cả tên nhãn lẫn độ khó đều nằm ngoài 41 đặc trưng đầu vào.

Các tệp ARFF kèm theo có 42 trường: 41 đặc trưng và lớp `normal`/`anomaly`, không có tên tấn công chi tiết hay độ khó. Đối chiếu từng dòng xác nhận 41 giá trị đặc trưng và nhãn nhị phân của mỗi ARFF khớp TXT tương ứng; sự khớp này không cho phép dùng ARFF để phục hồi tên tấn công. Sự phân biệt giữa hai định dạng cũng phù hợp với mô tả của UNB [2]. Train dùng cho phân tích thống kê và phát triển mô hình; Test giữ riêng cho đánh giá dự đoán.

2.3 Các đặc trưng mạng, loại biến và ý nghĩa

Đặc trưng (feature) là một thuộc tính mô tả quan sát, khác với nhãn (label) mô tả lớp hành vi. Đối chiếu bảng định nghĩa KDD với schema 41 tên trường cho phép tổ chức chúng thành bốn nhóm trong Bảng 2.2: 9 biến cơ bản, 13 biến nội dung, 9 biến lưu lượng theo thời gian và 10 biến lịch sử theo máy đích [3, 7]. Cách chia này mô tả nguồn thông tin của đặc trưng.

Bảng 2.2: Các nhóm đặc trưng theo nội dung đo lường

Nhóm	Số biến	Phạm vi	Ví dụ / đơn vị
Cơ bản	9	Thuộc tính của bản ghi kết nối	`duration` (giây), `src_bytes` (byte), giao thức
Nội dung	13	Dấu hiệu truy cập và thao tác trong kết nối	`logged_in` (chỉ báo), `num_failed_logins` (lần)
Lưu lượng theo thời gian	9	Tổng hợp trong cửa sổ hai giây	`count` (kết nối), `serror_rate` (tỷ lệ)
Lưu lượng theo máy đích	10	Tổng hợp theo lịch sử kết nối thay cho cửa sổ thời gian	`dst_host_count` (kết nối), các tỷ lệ theo máy đích

Ba biến danh nghĩa là `protocol_type` (giao thức, chẳng hạn TCP hoặc UDP), `service` (dịch vụ ở đích) và `flag` (trạng thái kết nối). Các mã danh mục không có khoảng cách số học để lấy trung bình. Trong 38 biến lưu dạng số, `duration` đo thời lượng theo giây; `src_bytes` và `dst_bytes` đo số byte theo hai chiều nguồn–đích. Chúng được ghi dưới dạng số nguyên; cách lưu số không đồng nghĩa mọi biến đều liên tục [3, 7].

`count` đếm kết nối tới cùng máy đích trong hai giây trước; `srv_count` đếm kết nối cùng dịch vụ trong cửa sổ đó. Hai điều kiện đếm khác nhau, nên nghiên cứu không mặc định một tập là tập con của tập kia. `serror_rate` là tỷ lệ kết nối có lỗi SYN[1] trong tập cùng máy đích; miền dự kiến là $[0, 1]$, không phải thang phần trăm. Các chỉ báo như `logged_in` biểu thị đăng nhập thành công, còn `su_attempted` được tài liệu mô tả là thử lệnh `su root`[2]. `num_outbound_cmds` đếm lệnh outbound trong phiên FTP[3] [3].

Miền giá trị dự kiến được đối chiếu với dữ liệu thực ở mục khảo sát chất lượng. Đặc trưng thứ 21 được ghi là `is_host_login` trong schema, nhưng mang tên `is_hot_login` trong bảng mô tả KDD, với ý nghĩa chỉ báo đăng nhập thuộc danh sách "hot". Al Tobi và Duncan cũng xác nhận sự không thống nhất tên gọi này đối với cùng đặc trưng [3, 7, 8]. Báo cáo thống nhất dùng `is_host_login` theo schema của dữ liệu nghiên cứu. Với nhóm lịch sử theo máy đích, tài liệu mô tả nguyên lý cửa sổ kết nối, nhưng chưa đủ để xác nhận mọi chi tiết triển khai trong bản NSL-KDD đang dùng. Các điểm chưa rõ được bảo lưu; kết quả kiểm toán miền được trình bày sau.

2.4 Hệ thống nhãn và các nhóm hành vi tấn công

Tên nhãn gốc mô tả hành vi cụ thể, chẳng hạn `normal`, `neptune` hoặc `portsweep`. Để mô tả cơ cấu, chúng được quy về Normal và bốn nhóm tấn công trong Bảng 2.3; định nghĩa nhóm dựa trên mô tả KDD, còn các ví dụ được đối chiếu danh sách ánh xạ UCI

[1] SYN là cờ điều khiển được dùng khi thiết lập kết nối TCP. Thuật ngữ lỗi SYN ở đây được sử dụng theo cách ghi nhận của bộ dữ liệu.

[2] Lệnh này yêu cầu chuyển sang tài khoản root, tài khoản có quyền quản trị hệ thống. Việc thử lệnh không đồng nghĩa đã chuyển quyền thành công.

[3] FTP là giao thức truyền tệp giữa các máy qua mạng.

[3, 4]. Đây là năm nhóm lưu lượng, không phải năm loại tấn công.

Bảng 2.3: Một nhóm bình thường và bốn nhóm tấn công

Nhóm	Ý nghĩa hành vi	Ví dụ nhãn gốc
Normal	Kết nối được gán nhãn hoạt động bình thường	`normal`
DoS	Từ chối dịch vụ, làm cản trở khả năng cung cấp dịch vụ	`neptune`, `smurf`
Probe	Thăm dò máy hoặc dịch vụ để thu thập thông tin	`portsweep`, `ipsweep`
R2L	Truy cập trái phép từ máy ở xa vào tài khoản cục bộ	`guess_passwd`, `ftp_write`
U2R	Từ quyền người dùng lên quyền quản trị trái phép	`buffer_overflow`, `rootkit`

Nhãn năm nhóm giữ khác biệt về dạng hành vi; nhãn nhị phân gộp bốn nhóm tấn công thành Attack (1) và giữ Normal (0), thích hợp cho so sánh bình thường/bất thường và bài toán dự đoán nhị phân. Kiểm kê tên gốc cho thấy Train có 23 giá trị, Test có 38 giá trị, đều tính cả `normal`; hợp hai tập có 40 giá trị, trong đó 17 tên chỉ xuất hiện ở Test. Số loại tấn công của KDD'99 không được dùng thay cho kết quả kiểm kê NSL-KDD này.

Với các nhãn mở rộng ở Test, nghiên cứu chọn hệ thống trong Bảng 3 của Imrana và cộng sự: `worm` thuộc DoS và `httptunnel` thuộc R2L [5]. Hệ thống phân loại này được lựa chọn theo nguồn đã nêu, không được suy luận từ tên nhãn. Cách xếp các nhãn này không thống nhất giữa mọi tài liệu; đổi nhóm sẽ thay đổi tần số năm nhóm ở Test nhưng không thay đổi nhãn nhị phân, vì cả hai vẫn là Attack. Mọi tần số được tính từ nhãn gốc theo cùng một ánh xạ, không chép số tổng từ bài báo. Kết quả kiểm tra tính đầy đủ và sự nhất quán của các bản ghi được trình bày ở mục khảo sát chất lượng dữ liệu; kết quả đối chiếu sau chuẩn hóa nhãn xác nhận không còn nhãn chưa ánh xạ và tổng tần số khớp số quan sát của từng tập.

2.5 Khảo sát chất lượng dữ liệu ban đầu

Để đánh giá mức độ tin cậy của các kết quả mô tả, dữ liệu được kiểm tra về cấu trúc, kiểu biến, tính đầy đủ, tính duy nhất và miền giá trị trước khi tổng hợp. Cấu trúc và thang đo đã được xác định ở các mục trước. Việc kiểm tra được thực hiện riêng cho từng tập theo các miền giá trị dự kiến; quá trình tuyển chọn khi xây dựng NSL-KDD không được xem là căn cứ để mặc định dữ liệu đã sạch.

Bảng 2.4 tổng hợp kết quả kiểm tra. Giá trị thiếu được đếm theo ô; chuỗi rỗng được kiểm tra sau khi bỏ khoảng trắng; giá trị vô hạn và lỗi chuyển kiểu số được kiểm tra ở các trường số. Việc kiểm tra trùng được thực hiện riêng trên toàn bộ 43 trường và trên 41 đặc trưng mạng.

Bảng 2.4: Kiểm tra cấu trúc và chất lượng của hai tập dữ liệu gốc

Tiêu chí / đơn vị	Train	Test
Quy mô (dòng)	125.973	22.544
Số trường trong TXT	43	43
Giá trị thiếu (ô)	0	0
Chuỗi rỗng / chỉ khoảng trắng (ô)	0	0
Giá trị vô hạn ở trường số (ô)	0	0
Lỗi chuyển kiểu số (ô)	0	0
Dòng lặp dư theo 43 trường	0	0
Dòng lặp dư theo 41 đặc trưng	16	57
Nhóm trùng 41 đặc trưng	15	57
Dòng thuộc nhóm trùng đặc trưng	31	114
Nhóm đặc trưng có nhãn gốc khác nhau	15	57
Dòng thuộc nhóm xung đột nhãn	31	114
Nhóm đặc trưng có cả Normal và Attack	7	54
Dòng thuộc nhóm xung đột nhị phân	14	108
Giá trị âm ở 38 đặc trưng số (ô)	0	0
Tỷ lệ ngoài $[0, 1]$ (ô)	0	0
Sai miền ở năm biến nhị phân (ô)	0	0
`su_attempted`=2 (dòng)	59	2
Đặc trưng hằng (biến)	1	1
Gần hằng, không hằng; tần suất mốt $\geq 99\%$ (biến)	12	10

Dòng lặp dư: số dòng còn lại sau khi giữ một dòng trong mỗi tổ hợp trùng. Nhóm trùng và dòng liên quan được đếm riêng; không cộng các dòng tiêu chí với nhau.

Hai tập không có dòng trùng hoàn toàn trên cả 43 trường, nhưng Train có 15 tổ hợp đặc trưng trùng, liên quan 31 quan sát và 16 dòng lặp dư; Test có 57 tổ hợp, liên quan 114 quan sát và 57 dòng lặp dư. Tất cả các tổ hợp trùng này có ít nhất hai nhãn gốc khác nhau. Khi gộp thành Normal/Attack, còn 7 nhóm xung đột ở Train (14 dòng) và 54 nhóm ở Test (108 dòng); các xung đột giữa hai tên tấn công cùng thuộc Attack không còn là xung đột nhị phân. Vì không có căn cứ xác định quan sát nào bị gán sai, các quan sát này được giữ nguyên. Sự khác nhau về nhãn cho thấy cùng một tổ hợp đặc trưng có thể tương ứng với nhiều nhãn trong dữ liệu. Xóa trùng chỉ theo đặc trưng sẽ tùy tiện giữ lại một nhãn, đồng thời làm thay đổi tần số mẫu.

Các đặc trưng số đều không âm; 15 biến tỷ lệ nằm trong $[0, 1]$. Năm chỉ báo được kiểm tra chỉ nhận 0 hoặc 1: `land`, `logged_in`, `root_shell`, `is_host_login` và `is_guest_login`. Riêng `su_attempted` có 59 quan sát Train và hai quan sát Test nhận giá trị 2, không phù hợp mô tả nhị phân của lệnh `su root` trong tài liệu gốc [3]. Giá trị này được giữ nguyên và được ghi nhận là điểm chưa thống nhất giữa dữ liệu và mô tả ý nghĩa của biến; nghiên cứu không tự đổi giá trị đó thành 0 hoặc 1.

Biến `num_outbound_cmds` luôn bằng 0 ở cả hai tập. Nếu định nghĩa gần hằng là

tần suất của giá trị phổ biến nhất đạt ít nhất 99%, không tính biến hằng, Train có 12 biến và Test có 10 biến thuộc diện này. Một biến có giá trị giống nhau hoặc ít thay đổi giữa các quan sát không đồng nghĩa các quan sát tương ứng bị lỗi.

Nghiên cứu sử dụng ngưỡng thăm dò ngoại lai là $[Q_1 - 1{,}5\,IQR,\ Q_3 + 1{,}5\,IQR]$, với $IQR = Q_3 - Q_1$. Tuy nhiên, ở `duration`, $Q_1 = Q_3 = 0$ và 92,05% quan sát bằng 0; ngưỡng IQR khi đó đánh dấu mọi thời lượng dương và không còn hữu ích để phân biệt các giá trị bị ghi nhận sai. Giá trị cực đại của `src_bytes` đạt 1.379.963.888 byte. Giá trị cực đại lớn này cho thấy cần thận trọng khi diễn giải trung bình, nhưng chưa đủ làm căn cứ loại dữ liệu vì lưu lượng cực đoan có thể liên quan đến hành vi tấn công. Vì vậy, nghiên cứu không áp dụng cắt ngọn hay tự động loại bỏ các quan sát ngoại lai.

2.6 Các bước làm sạch và chuẩn hóa nhãn

Do không phát hiện thiếu dữ liệu, lỗi kiểu số hoặc giá trị âm, nghiên cứu không áp dụng điền khuyết hay loại dòng. Những vấn đề quan sát được gồm xung đột nhãn tại cùng đặc trưng và giá trị 2 của `su_attempted` được bảo toàn để tránh áp đặt giả định không kiểm chứng. Các trường danh mục được giữ nguyên cách viết của schema, không chuyển thành mã số rồi coi đó là đại lượng có thể lấy trung bình.

Tên tấn công trong TXT được giữ ở `attack_name`; từ đó tạo `attack_category` theo thứ tự Normal, DoS, Probe, R2L, U2R và `label_binary`, với Normal bằng 0 và Attack bằng 1. Việc ánh xạ áp dụng hệ thống nhãn và nguồn phân loại đã nêu ở mục trước; tên gốc được bảo toàn để truy vết, còn tần số nhóm được tính từ các bản ghi thực tế. Toàn bộ 40 giá trị tên nhãn quan sát được trong hợp hai tập (kể cả Normal) đều được ánh xạ; tên ngoài danh sách sẽ làm dừng xử lý trước khi xuất dữ liệu.

Bảng 2.5 cho thấy số dòng và 41 đặc trưng không thay đổi; hai nhãn dẫn xuất làm tổng số trường tăng từ 43 lên 45. Sau xử lý, không còn nhãn chưa ánh xạ; tổng tần số của năm nhóm và tổng Normal/Attack đều bằng đúng số quan sát của từng tập.

Bảng 2.5: Đối chiếu dữ liệu trước và sau chuẩn hóa nhãn

Chỉ tiêu	Train		Test	
	Trước	Sau	Trước	Sau
Số dòng	125.973	125.973	22.544	22.544
Tổng số trường	43	45	43	45
Đặc trưng mạng	41	41	41	41
Nhãn dẫn xuất bổ sung	0	2	0	2
Giá trị thiếu (ô)	0	0	0	0
Dòng bị loại	—	0	—	0
Tổng nhãn năm nhóm	—	125.973	—	22.544
Tổng Normal/Attack	—	125.973	—	22.544

Giữ nguyên 41 đặc trưng, `attack_name` và `difficulty`; bổ sung nhãn nhóm và nhãn nhị phân.

Trường `difficulty` vẫn được lưu để truy vết nhưng không dùng làm biến dự đoán: nó phản ánh mức độ các bộ phân loại dùng khi xây dựng dữ liệu dự đoán đúng quan sát, thay vì một thuộc tính của lưu lượng có sẵn khi phát hiện xâm nhập [2]. Các bảng mô tả dùng thang đo gốc; nghiên cứu không áp dụng Z-score, MinMax hay one-hot cho mọi phân tích. Nếu cần các phép biến đổi này cho hồi quy Logistic, tham số chỉ được học từ Train rồi áp dụng nguyên trạng lên Test.

2.7 Quy ước bộ dữ liệu dùng cho từng phân tích

Theo quy ước nghiên cứu được lựa chọn cho bài này, KDDTrain+ là mẫu chính để mô tả phân bố đặc trưng, tần số nhãn và thực hiện các phân tích thống kê. KDDTest+ được giữ riêng cho đánh giá dự đoán. Việc khảo sát chất lượng Test ở trên chỉ nhằm xác nhận dữ liệu có thể đọc và nhãn có thể đối chiếu, không dùng để chọn biến hoặc điều chỉnh tham số. Các tỷ lệ trong Chương 4 được tính riêng trên Train, không cộng hai tập.

Đối với biến định lượng, các đại lượng trung tâm và phân tán được tính theo đơn vị gốc; biến định tính như dịch vụ ở đích (`service`) và trạng thái kết nối (`flag`) được tổng hợp bằng tần số hoặc bảng chéo. Nhãn năm nhóm phục vụ mô tả cơ cấu các dạng lưu lượng, còn nhãn nhị phân phục vụ so sánh Normal/Attack. Các nhãn và `difficulty` bị loại khỏi tập biến dự đoán; tên tấn công gốc được giữ để đối chiếu. Mọi bước mã hóa, chuẩn hóa và lựa chọn đặc trưng có học tham số chỉ sử dụng Train.

Các kết quả sau đây mô tả mẫu NSL-KDD đã được tuyển chọn, không ước lượng tỷ lệ tấn công trên Internet. Nguồn dữ liệu cũng lưu ý hạn chế đại diện cho mạng thực [2]. Quy ước này bảo đảm các kết quả mô tả ở Chương 4 có cùng mẫu nền và giữ ranh giới với đánh giá dự đoán.

Chương 3

Phương pháp Xác suất và Thống kê

3.1 Thiết kế phân tích và quy ước thống kê chung

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

3.2 Thống kê mô tả và trực quan hóa dữ liệu

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

3.3 Phân tích tương quan Pearson

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

3.4 Ước lượng khoảng tin cậy Wilson cho tỷ lệ

3.4.1 Mục đích và tham số

Nhóm sử dụng khoảng tin cậy Wilson để lượng hóa độ bất định của tỷ lệ năm nhóm Normal, DoS, Probe, R2L và U2R trong KDDTrain+. Với nhóm g, tham số cần ước lượng là $p_g = P(Y = g)$; nếu có x_g trong tổng số n bản ghi thuộc nhóm đó thì ước lượng điểm là $\widehat{p}_g = \frac{x_g}{n}$. Mỗi nhóm được xét như một biến chỉ báo nhị thức "thuộc nhóm g" hoặc "không thuộc nhóm g".

3.4.2 Công thức

Với mức tin cậy $1 - \alpha$ và $z = z_{1-\frac{\alpha}{2}}$, khoảng Wilson là

$$\frac{\widehat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}.$$

Nghiên cứu dùng $\alpha = 0{,}05$, do đó $z \approx 1{,}96$. So với khoảng Wald $\widehat{p} \pm z\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}$, Wilson ổn định hơn khi tỷ lệ gần 0 hoặc 1 và không tạo cận ngoài miền $[0, 1]$; đặc điểm này quan trọng đối với nhóm U2R rất hiếm.

3.4.3 Giả định và điều kiện áp dụng

Các bản ghi được giả định độc lập, nhãn nhóm loại trừ lẫn nhau và phép ánh xạ nhãn không sai. Khoảng Wilson không đòi hỏi xấp xỉ chuẩn của $\widehat{p}$ tốt như khoảng Wald, nhưng vẫn dựa trên mô hình nhị thức và không tự xử lý sự phụ thuộc giữa các kết nối. Năm khoảng được tính riêng, không phải một miền tin cậy đồng thời cho toàn bộ vector $(p_1, \ldots, p_5)$; sự chồng lấp hay không chồng lấp của chúng cũng không thay thế một kiểm định so sánh tỷ lệ.

3.4.4 Cách sử dụng trong bộ dữ liệu

Nhóm đếm năm nhãn trên toàn bộ 125.973 bản ghi KDDTrain+, không gộp KDDTest+ và không dùng dữ liệu SMOTE. Kết quả chỉ mô tả cơ cấu của mẫu train đã tuyển chọn, không được diễn giải thành tỷ lệ tấn công của Internet hiện tại. Ước lượng điểm, cận dưới và cận trên được trình bày tại Mục 4.4.

3.5 Phân tích phương sai một yếu tố và phương án Welch

3.5.1 Mục đích và lựa chọn biến

ANOVA một yếu tố được dùng để đánh giá liệu trung bình của một đặc trưng định lượng có giống nhau giữa Normal, DoS, Probe, R2L và U2R hay không. Bốn đặc trưng được chọn theo ý nghĩa đo lường bổ sung nhau: `count` đại diện cường độ kết nối gần đây, `serror_rate` phản ánh lỗi SYN, `src_bytes` đo lượng dữ liệu gửi từ nguồn và `duration` đo thời gian duy trì kết nối. Chúng đồng thời đại diện cho bốn dạng dữ liệu khác nhau (biến đếm, tỷ lệ bị chặn, dữ liệu đuôi phải và dữ liệu nhiều số 0), đủ để trả lời các câu hỏi nghiên cứu có cơ sở mà không biến ANOVA thành bước sàng lọc toàn bộ 41 đặc trưng. Các biến định tính như `service` hay `flag` không phù hợp làm biến phụ thuộc của ANOVA.

3.5.2 Giả thuyết

Với mỗi đặc trưng, nhóm kiểm định

$$H_0 : \mu_{\text{Normal}} = \mu_{\text{DoS}} = \mu_{\text{Probe}} = \mu_{\text{R2L}} = \mu_{\text{U2R}}, \qquad H_1 : \text{có ít nhất một trung bình khác},$$

ở mức ý nghĩa $\alpha = 0{,}05$. Một kiểm định tổng thể có ý nghĩa chỉ cho biết ít nhất một cặp khác nhau, không khẳng định mọi cặp đều khác.

3.5.3 ANOVA cổ điển và kích thước ảnh hưởng

Gọi k là số nhóm, N là tổng cỡ mẫu, $\bar{x}_i$ là trung bình nhóm và $\bar{x}$ là trung bình chung. ANOVA cổ điển phân rã

$$SS_B = \sum_{i=1}^{k} n_i(\bar{x}_i - \bar{x})^2, \qquad SS_W = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(x_{ij} - \bar{x}_i)^2,$$

và dùng

$$F = \frac{\frac{SS_B}{k-1}}{\frac{SS_W}{N-k}}.$$

Nhóm báo cáo thêm $\eta^2 = \frac{SS_B}{SS_B+SS_W}$ và ω^2 như các chỉ số mô tả tỷ phần biến thiên gắn với nhóm. Khi kiểm định chính là Welch, các chỉ số dựa trên tổng bình phương cổ điển được ghi rõ là mô tả, không suy ra trực tiếp từ Welch F.

3.5.4 Phương án Welch

Do cỡ mẫu rất mất cân bằng và phương sai khác nhau, kết quả chính dùng Welch ANOVA. Đặt $w_i = \frac{n_i}{s_i^2}$, $W = \sum_i w_i$ và $\bar{x}_w = \frac{\sum_i w_i \bar{x}_i}{W}$. Thống kê Welch được viết

$$F_W = \frac{\dfrac{\sum_i w_i(\bar{x}_i - \bar{x}_w)^2}{k-1}}{1 + \dfrac{2(k-2)}{k^2-1}\displaystyle\sum_i \frac{\left(1 - \frac{w_i}{W}\right)^2}{n_i - 1}},$$

với $df_1 = k - 1$ và

$$df_2 = \frac{k^2 - 1}{3\displaystyle\sum_i \frac{\left(1 - \frac{w_i}{W}\right)^2}{n_i - 1}}.$$

Nếu kiểm định tổng thể có ý nghĩa, Games–Howell được dùng cho 10 cặp vì không yêu cầu phương sai hoặc cỡ mẫu bằng nhau. Hiệu chỉnh trong Games–Howell áp dụng cho các cặp trong từng RQ; hiệu chỉnh Holm được áp dụng riêng cho bốn p-value tổng thể.

3.5.5 Giả định, chẩn đoán và thang phân tích

Các quan sát được giả định độc lập; phân bố trong nhóm không nên quá bất thường đối với suy luận về trung bình; và ngoại lệ không được tự ý xóa để làm đẹp kết quả. Nhóm đánh giá hình dạng bằng trung bình–trung vị, skewness, ECDF và Q–Q plot; đánh giá phương sai bằng Brown–Forsythe; đồng thời xem xét chênh lệch cỡ mẫu và tỷ lệ bằng 0. Shapiro–Wilk trên mẫu lớn chỉ là chẩn đoán bổ sung, không phải tiêu chí duy nhất để chọn kiểm định. `count` và `serror_rate` được kiểm định trên thang gốc để giữ câu hỏi về trung bình gốc. Do lệch phải và cực trị mạnh, `src_bytes` và `duration` dùng

$\ln(1+x)$; kết quả của chúng vì vậy nói về trung bình sau biến đổi, không phải trực tiếp về số byte hay số giây trung bình trên thang gốc.

3.5.6 Lấy mẫu phục vụ biểu đồ

Mọi thống kê mô tả và kiểm định đều dùng toàn bộ 125.973 bản ghi. Chỉ bước trực quan hóa dùng tối đa 5.000 quan sát/nhóm cho ECDF và 1.000 quan sát/nhóm cho Q–Q plot, với `random_state`=18015; nhóm nhỏ hơn ngưỡng được giữ toàn bộ. Các ngưỡng này đủ lớn để thể hiện ổn định vị trí, đuôi và khối lượng tại 0, đồng thời tránh hàng chục nghìn điểm chồng lấp, giảm kích thước hình và giữ nhãn có thể đọc khi in. Vì mẫu giảm chỉ dùng để vẽ, nó không làm thay đổi F, p-value, khoảng tin cậy, effect size hay hậu kiểm. Kết quả được trình bày tại Mục 4.5.

3.6 Kiểm định độc lập Chi-square và Cramér's V

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

3.7 Hồi quy Logistic nhị phân và đánh giá mô hình

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

Chương 4

Kết quả và thảo luận

4.1 Kết quả thống kê mô tả

Câu hỏi mô tả đặt ra là các đặc trưng lưu lượng có xu hướng trung tâm, mức phân tán và hình dạng phân bố như thế nào trong KDDTrain+ ($n = 125.973$). Sáu biến đại diện được chọn theo ý nghĩa đo lường: `duration` phản ánh thời lượng kết nối; `src_bytes` và `dst_bytes` phản ánh lượng dữ liệu hai chiều; `count` và `srv_count` thể hiện số kết nối trong cửa sổ hai giây, lần lượt tới cùng máy đích và cùng dịch vụ; `serror_rate` là tỷ lệ lỗi SYN trong các kết nối cùng máy đích [3]. Lựa chọn này bao quát thời gian, lưu lượng, hoạt động kết nối và lỗi giao thức, không dựa trên kết quả của Test.

Bảng 4.1 trình bày trung bình, trung vị, độ lệch chuẩn và cực trị. Bảng 4.2 bổ sung các phân vị và tỷ lệ bằng 0 để đánh giá mức độ trung bình đại diện cho quan sát điển hình. Phương sai và độ lệch chuẩn mẫu dùng mẫu số $n-1$; phân vị sử dụng nội suy tuyến tính tại vị trí $(n-1)p$ trong dãy đã sắp xếp (chỉ số bắt đầu từ 0). Các đặc trưng đều có đủ n quan sát.

Bảng 4.1: Xu hướng trung tâm và độ phân tán trên KDDTrain+ ($n = 125.973$ cho mỗi biến)

Đặc trưng	Trung bình	Trung vị	ĐLC mẫu	Min	Max
`duration`	287,14	0,00	2.604,52	0	42.908
`src_bytes`	45.566,74	44,00	5.870.331,18	0	1.380e09
`dst_bytes`	19.779,11	0,00	4.021.269,15	0	1.310e09
`count`	84,11	14,00	114,51	0	511
`srv_count`	27,74	8,00	72,64	0	511
`serror_rate`	0,284	0,000	0,446	0	1

`duration`: giây; `src_bytes`, `dst_bytes`: byte; `count`, `srv_count`: số kết nối; `serror_rate`: tỷ lệ 0–1. Ký hiệu eN nghĩa là nhân 10^N.

Bảng 4.2: Phân vị, phương sai mẫu và tỷ lệ bằng 0 trên KDDTrain+

Đặc trưng	Q_1	Q_3	IQR	Phương sai mẫu	Bằng 0 (%)
`duration`	0	0	0	6.783.500,00	92,05
`src_bytes`	0	276	276	3.446e13	39,21
`dst_bytes`	0	516	516	1.617e13	53,95
`count`	2	143	141	13.112,22	0,01
`srv_count`	2	18	16	5.275,97	0,01
`serror_rate`	0	1	1	0,199	68,93

Phương sai có đơn vị bình phương: giây^2, byte^2, kết nối^2; phương sai của tỷ lệ không có đơn vị vật lý. IQR giữ đơn vị gốc.

Thời lượng có trung vị 0 giây và 92,05% quan sát bằng 0, trong khi trung bình là 287,14 giây và cực đại 42.908 giây. Số 0 là giá trị được ghi ở độ phân giải giây, không nhất thiết có nghĩa không tồn tại kết nối. Việc các phân vị 25%, 50% và 75% cùng bằng 0 cho thấy trung bình bị chi phối bởi phần nhỏ quan sát có thời lượng lớn; chỉ báo này cần được đọc cùng phân vị thay vì xem như thời lượng điển hình.

Hai biến byte đều lệch mạnh về phía giá trị lớn. Với `src_bytes`, trung bình 45.566,74 byte vượt xa trung vị 44 byte, còn độ lệch chuẩn đạt 5.870.331,18 byte. Với `dst_bytes`, hơn một nửa quan sát bằng 0 (53,95%), dù trung bình đạt 19.779,11 byte. Các cực trị rất lớn làm phương sai tăng mạnh, nhưng chỉ từ bảng mô tả, nghiên cứu chưa xác định được các cực trị này là lỗi ghi nhận hay phản ánh hành vi mạng đặc thù.

`count` có trung bình 84,11 và trung vị 14 kết nối, cao hơn các chỉ tiêu tương ứng của `srv_count` (27,74 và 8). Hai biến sử dụng điều kiện đếm khác nhau nên không được suy ra quan hệ tập con từ chênh lệch này. `serror_rate` có trung vị 0 nhưng $Q_3 = 1$, cho thấy đồng thời có nhiều quan sát không có lỗi SYN và một phần đáng kể ở tỷ lệ lỗi cao. Đặc điểm này là cơ sở để nghiên cứu tiếp tục xem xét phân bố theo nhãn, bên cạnh trung bình toàn mẫu.

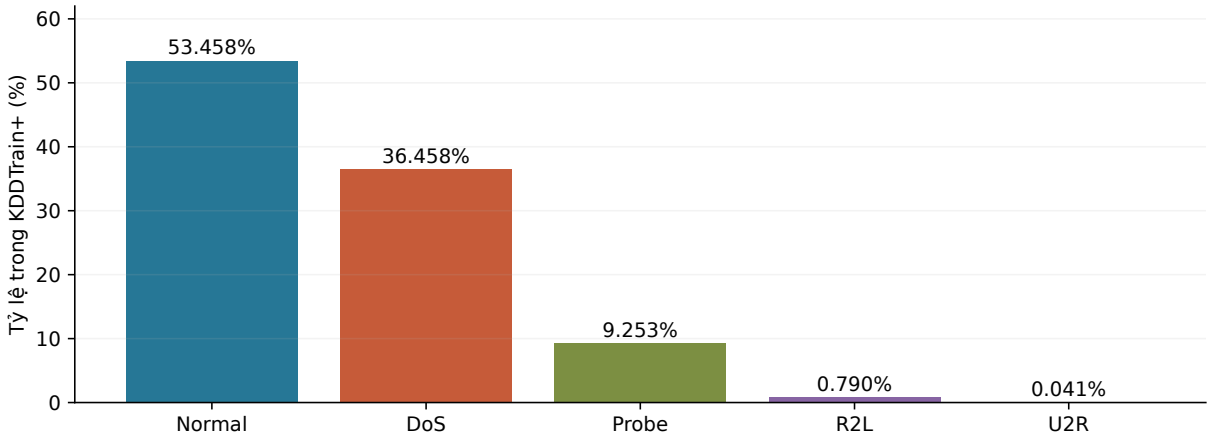
4.2 Phân bố nhãn và so sánh đặc trưng Normal/Attack

Bảng 4.3 và Hình 4.1 cho thấy cơ cấu gồm Normal và bốn nhóm tấn công. Normal chiếm 53,458%, Attack chiếm 46,542%; tuy hai nhãn nhị phân có quy mô tương đối gần nhau, cơ cấu bên trong Attack mất cân bằng rõ rệt. DoS có 45.927 quan sát, còn R2L chỉ có 995 và U2R chỉ có 52. Vì vậy, sự cân đối tương đối của bài toán nhị phân không đồng nghĩa năm nhóm đều có số quan sát tương tự.

Bảng 4.3: Phân bố năm nhóm và tổng hợp nhị phân trên KDDTrain+

Nhãn	Tần số	Tỷ lệ (%)
Normal	67.343	53,458
DoS	45.927	36,458
Probe	11.656	9,253
R2L	995	0,790
U2R	52	0,041
Tổng	125.973	100,000
Normal (nhị phân)	67.343	53,458
Attack (nhị phân)	58.630	46,542

Attack là tổng DoS, Probe, R2L và U2R; hai hàng nhị phân là cách gộp lại cùng mẫu, không cộng thêm vào tổng năm nhóm.



Hình 4.1: Tỷ lệ Normal và bốn nhóm tấn công trên KDDTrain+ ($n = 125.973$). Trục tung tuyến tính; giá trị ghi trên cột giúp nhận biết hai nhóm hiếm.

Tỷ lệ DoS cao khiến các đặc điểm của nhóm tấn công này có thể chi phối kết quả gộp Attack. R2L và U2R có số quan sát nhỏ nên kết quả mô tả Attack không được xem là mô tả riêng cho hai nhóm đó. Các tỷ lệ ở Bảng 4.3 phản ánh thành phần mẫu được cung cấp, không phản ánh xác suất gặp tấn công trong mạng đang vận hành.

Để so sánh hai nhãn, ba đặc trưng được chọn vì có cơ chế diễn giải bổ sung nhau: `src_bytes` đo dữ liệu truyền từ nguồn, `count` đo mức tập trung kết nối tới máy đích trong hai giây, còn `serror_rate` phản ánh lỗi SYN. Bảng 4.4 so sánh trực tiếp hai nhóm, còn Hình 4.2 mô tả toàn bộ phân bố và Hình 4.3 nhấn mạnh trung vị, khoảng tứ phân vị và các điểm xa hộp.

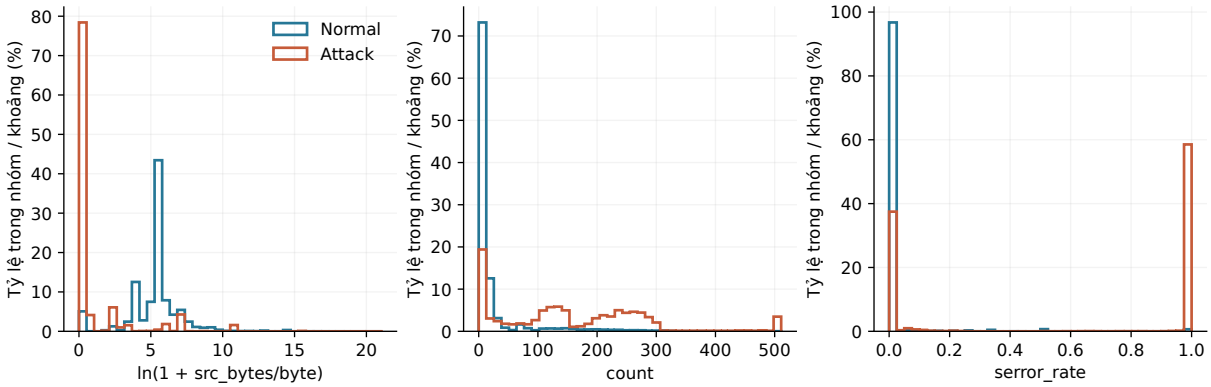
Bảng 4.4: So sánh trực tiếp Normal và Attack trên KDDTrain+

Đặc trưng	Nhóm (n)	TB	Trung vị	ĐLC mẫu	Q_1–Q_3
`src_bytes`	Normal (67.343)	13.133,28	233	418.113,13	129–324
`src_bytes`	Attack (58.630)	82.820,14	0	8.593.024,60	0–0
`count`	Normal (67.343)	22,52	4	54,03	1–14
`count`	Attack (58.630)	154,85	138	124,33	40–241
`serror_rate`	Normal (67.343)	0,013	0	0,094	0–0
`serror_rate`	Attack (58.630)	0,596	1	0,487	0–1

TB: trung bình; ĐLC: độ lệch chuẩn. `src_bytes`: byte; `count`: kết nối; `serror_rate`: tỷ lệ 0–1. Tính trên dữ liệu gốc, không logarit hóa.

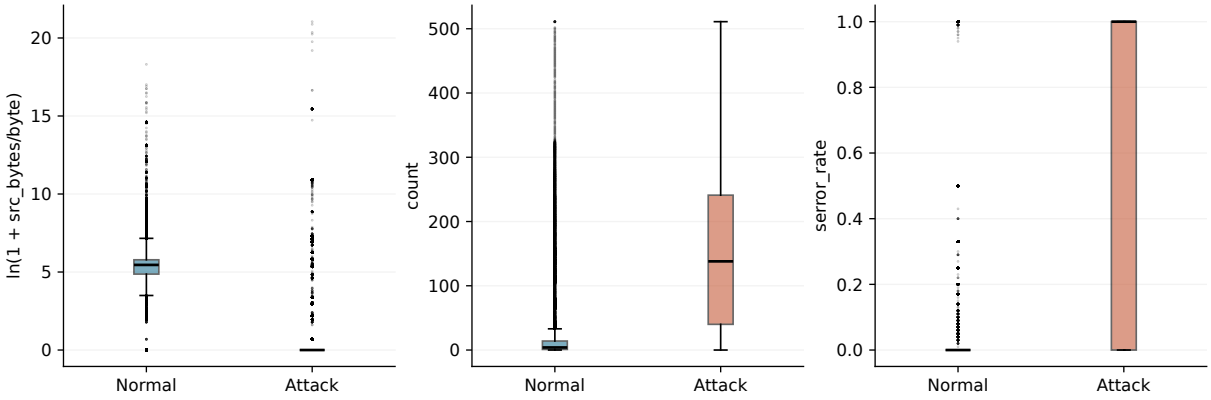
Trung vị `count` ở Attack là 138, so với 4 ở Normal, tức cao hơn 134 kết nối; khoảng tứ phân vị tương ứng là 40–241 và 1–14. Điều này phù hợp với một số hành vi tạo nhiều kết nối trong thời gian ngắn như từ chối dịch vụ hoặc thăm dò. Tuy nhiên, cả hai nhóm đều có giá trị từ 0 đến 511, nên miền giá trị vẫn chồng lấp và không thể dùng riêng số kết nối để nhận diện mọi cuộc tấn công.

Với `serror_rate`, trung bình Attack là 0,596, so với 0,013 ở Normal; trung vị lần lượt là 1 và 0. Mặc dù lỗi SYN tập trung rõ hơn trong Attack, 36,99% quan sát Attack vẫn có tỷ lệ lỗi bằng 0, còn 3,27% Normal có tỷ lệ lỗi dương. Sự chồng lấp quan sát được này cho thấy ngưỡng có lỗi/không lỗi sẽ bỏ sót một phần tấn công và gắn cờ một phần kết nối bình thường.



Hình 4.2: Histogram so sánh trên KDDTrain+: mỗi nhóm được chuẩn hóa riêng để tổng chiều cao các khoảng bằng 100%; dùng cùng 40 khoảng chia đều cho hai nhóm ở từng ô. `src_bytes` chỉ đổi thang trực quan thành $\ln(1 + x/\text{byte})$; hai biến còn lại giữ thang gốc. Không cắt miền giá trị.

Histogram cho thấy khác biệt của `src_bytes` không thể tóm tắt bằng trung bình: Attack có trung bình 82.820,14 byte, cao hơn Normal (13.133,28 byte), nhưng trung vị Attack bằng 0, thấp hơn Normal (233 byte). Trong Attack, 78,42% giá trị bằng 0, so với 5,07% ở Normal. Phân bố vì vậy vừa có khối lượng lớn tại 0 vừa có đuôi phải rất dài. Trung bình cao không có nghĩa một kết nối Attack điển hình truyền nhiều byte hơn.



Hình 4.3: Boxplot theo nhãn trên KDDTrain+. Hộp biểu diễn Q_1–Q_3, đường giữa là trung vị; râu tới quan sát xa nhất còn trong ngưỡng $1{,}5\,IQR$ trên thang vẽ; các điểm ngoài râu vẫn được hiển thị. Chỉ `src_bytes` dùng $\ln(1 + x/\text{byte})$, giữ toàn bộ miền.

Boxplot làm nổi bật khoảng tứ phân vị của `count` ở Attack dịch lên cao. Tuy nhiên, hộp `src_bytes` của Attack co lại ở 0 do $Q_1 = Q_3 = 0$; hộp `serror_rate` của Normal cũng co tại 0. Khi IQR bằng 0, các điểm ngoài hộp không tự động là dữ liệu sai. Phép logarit giúp nhìn phần đuôi của biến byte nhưng không làm biến mất sự chồng lấp giữa hai nhãn. Các khác biệt nêu trên chỉ là kết quả mô tả, chưa xác lập ý nghĩa thống kê, quan hệ nhân quả hay hiệu quả dự đoán.

4.3 Kết quả phân tích tương quan Pearson

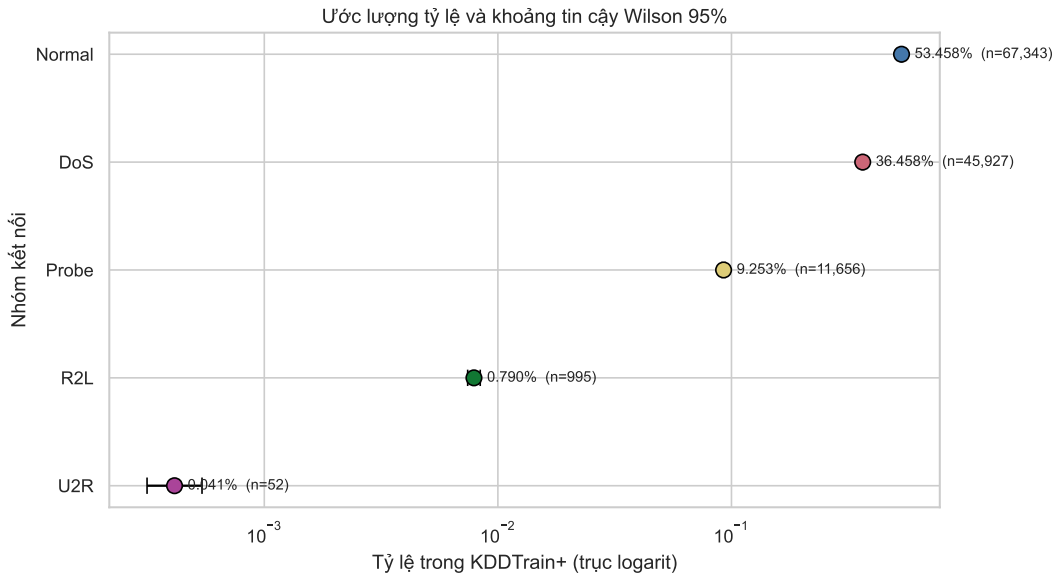
[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

4.4 Kết quả khoảng tin cậy 95% cho năm nhóm

Theo quy trình tại Mục 3.4, Bảng 4.5 và Hình 4.4 trình bày ước lượng Wilson từ toàn bộ KDDTrain+ ($n = 125.973$). Các giá trị mô tả cơ cấu của mẫu train, không phải tỷ lệ tấn công của Internet hiện tại.

Bảng 4.5: Ước lượng tỷ lệ và khoảng tin cậy Wilson 95% trên KDDTrain+

Nhóm	Số quan sát	Tỷ lệ (%)	Khoảng tin cậy 95% (%)
Normal	67.343	53,458	[53,183; 53,734]
DoS	45.927	36,458	[36,192; 36,724]
Probe	11.656	9,253	[9,094; 9,414]
R2L	995	0,790	[0,742; 0,840]
U2R	52	0,041	[0,031; 0,054]
Tổng	125.973	100,000	–



Hình 4.4: Ước lượng điểm và khoảng tin cậy Wilson 95% cho năm nhóm. Trục tỷ lệ dùng thang logarit để khoảng của R2L và U2R vẫn quan sát được; kích thước mẫu được ghi cạnh mỗi điểm.

Normal chiếm tỷ trọng lớn nhất, 53,458% (KTC 95%: 53,183–53,734%), tiếp đến là DoS với 36,458% (36,192–36,724%) và Probe với 9,253% (9,094–9,414%). Hai nhóm hiếm R2L và U2R chỉ chiếm lần lượt 0,790% và 0,041%. Khoảng của U2R rộng hơn theo tỷ lệ tương đối vì chỉ có 52 quan sát. Sự mất cân bằng này báo trước độ bất định lớn hơn cho các ước lượng và hậu kiểm liên quan đến U2R; các khoảng riêng lẻ không được dùng như một kiểm định so sánh tỷ lệ.

4.5 Kết quả ANOVA, kiểm tra giả định và hậu kiểm

Phần này áp dụng quy trình tại Mục 3.5 cho bốn câu hỏi nghiên cứu. Kết quả chính dùng Welch ANOVA; hậu kiểm dùng Games–Howell và bốn p-value tổng thể được hiệu chỉnh Holm. Các bảng mô tả vẫn giữ đơn vị gốc để hỗ trợ diễn giải thực tế.

4.5.1 Thống kê mô tả và kiểm tra giả định

Bảng 4.6 cho thấy trung bình và trung vị khác nhau đáng kể ở nhiều nhóm. Đặc biệt, trung bình `src_bytes` của Probe đạt 385.679,84 byte nhưng trung vị chỉ là 1 byte; `duration` của Probe có trung bình 2.074,86 giây nhưng trung vị bằng 0. Đây là dấu hiệu đuôi phải dài và khối lượng lớn tại 0, không phải bằng chứng để tùy tiện loại ngoại lệ.

Bảng 4.6: Trung bình và trung vị theo nhóm trên thang gốc

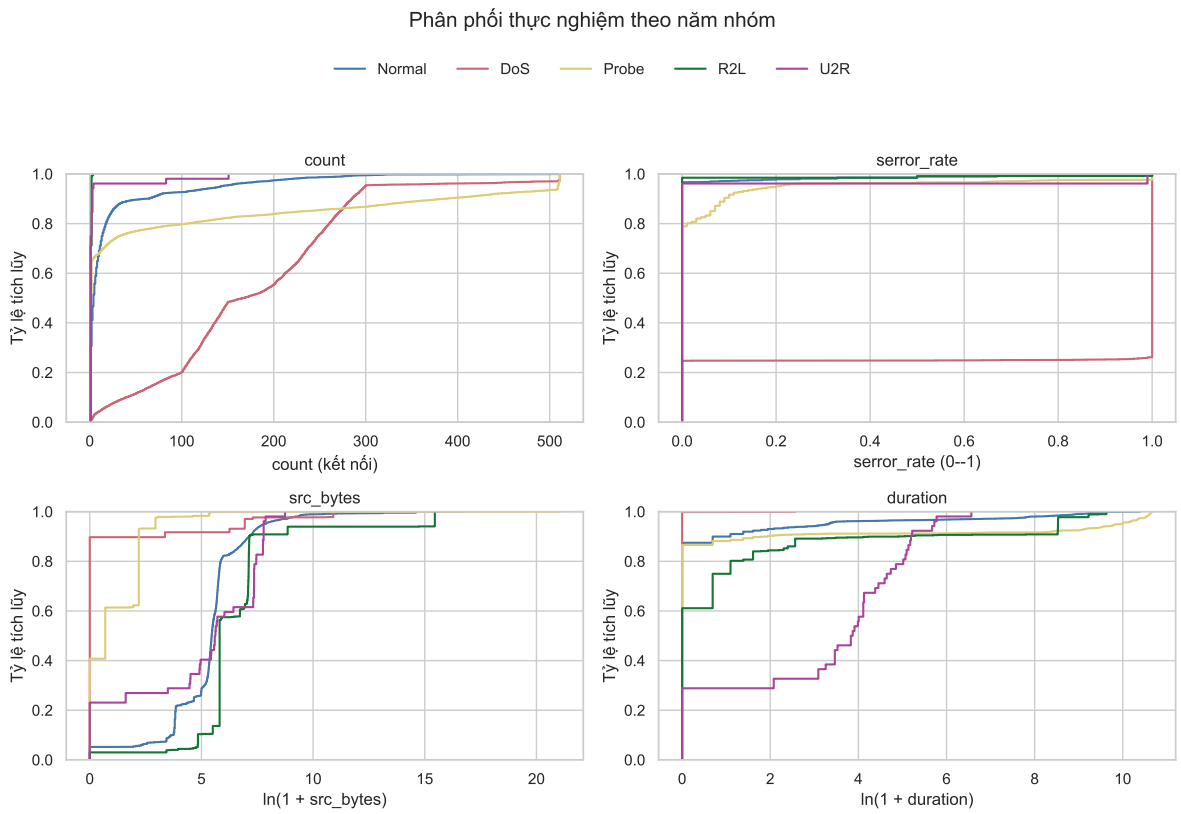
Đặc trưng	Thống kê	Normal	DoS	Probe	R2L	U2R
`count`	Trung bình	22,52	178,09	77,05	1,30	5,81
	Trung vị	4	172	1	1	1
`serror_rate`	Trung bình	0,013	0,748	0,047	0,012	0,038
	Trung vị	0	1	0	0	0
`src_bytes`	Trung bình	13.133,28	1.176,32	385.679,84	307.727,30	906,23
	Trung vị	233	0	1	334	273
`duration`	Trung bình	168,59	0,006	2.074,86	633,42	80,94
	Trung vị	0	0	0	0	46

Cỡ mẫu theo thứ tự Normal, DoS, Probe, R2L, U2R là 67.343, 45.927, 11.656, 995 và 52. `count`: kết nối; `src_bytes`: byte; `duration`: giây; `serror_rate`: tỷ lệ 0–1.

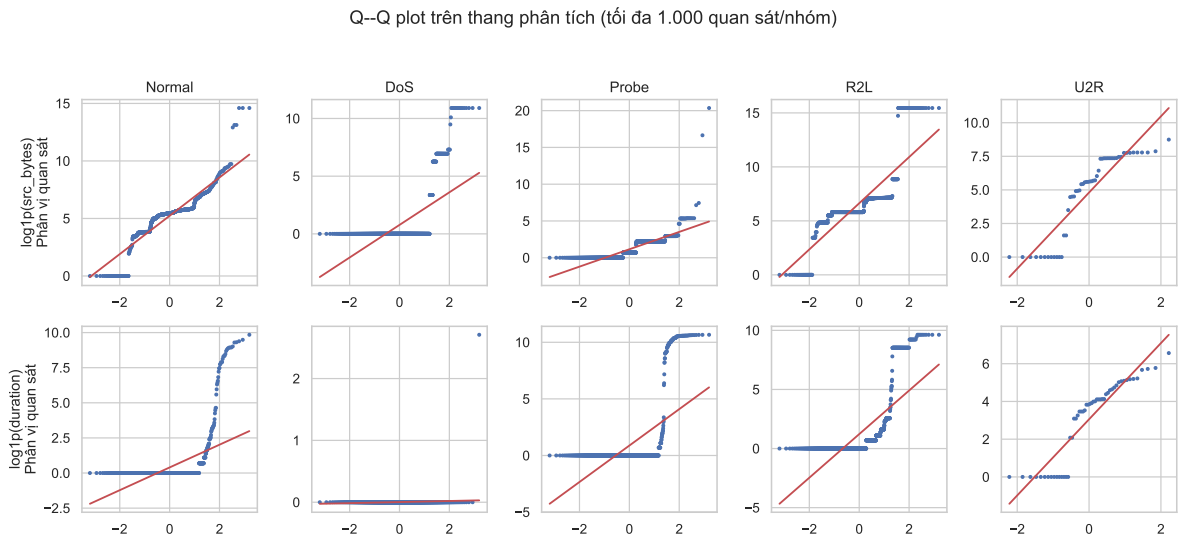
Brown–Forsythe bác bỏ đồng nhất phương sai ở cả bốn đặc trưng (Bảng 4.7); tỷ số cỡ mẫu lớn nhất/nhỏ nhất đạt 1.295,1. ECDF ở Hình 4.5 và Q–Q plot ở Hình 4.6 đồng thời cho thấy dữ liệu bị chặn, nhiều số 0 hoặc có đuôi dài. Các dấu hiệu này, thay vì chỉ một p-value Shapiro–Wilk, là cơ sở chọn Welch và thang $\ln(1+x)$ cho hai biến lệch mạnh.

Bảng 4.7: Kiểm tra giả định trên thang dùng cho kiểm định chính

Đặc trưng	Thang phân tích	Brown–Forsythe	p-value	Chẩn đoán trọng tâm
`count`	Gốc	5.817,05	$< 10^{-300}$	Biến đếm; |skew| tối đa 5,56; U2R nhỏ.
`serror_rate`	Gốc	5.279,29	$< 10^{-300}$	Bị chặn 0–1, dồn tại hai biên; |skew| tối đa 8,85.
`src_bytes`	$\ln(1+x)$	364,36	$1{,}59 \times 10^{-312}$	Thang gốc có cực trị lớn; sau log vẫn chưa chuẩn hoàn toàn.
`duration`	$\ln(1+x)$	1.318,15	$< 10^{-300}$	Nhiều số 0; |skew| tối đa 38,03 do nhóm DoS.



Hình 4.5: ECDF theo năm nhóm. `src_bytes` và `duration` dùng $\ln(1+x)$; lấy mẫu cố định tối đa 5.000 quan sát/nhóm chỉ để vẽ theo quy trình ở Mục 3.5. Mọi kiểm định sử dụng toàn bộ dữ liệu.



Hình 4.6: Q–Q plot của $\log(1+\texttt{src_bytes})$ và $\log(1+\texttt{duration})$, dùng tối đa 1.000 quan sát/nhóm. Các điểm lệch đường tham chiếu cho thấy phép log giảm nhưng không loại bỏ hoàn toàn sai lệch chuẩn.

4.5.2 Kết quả kiểm định tổng thể và kích thước ảnh hưởng

Bảng 4.8 bác bỏ H_0 cho cả bốn câu hỏi, kể cả sau hiệu chỉnh Holm. Các p-value dưới giới hạn hiển thị được báo cáo là $p < 10^{-300}$, không viết $p = 0$. Kết quả của `src_bytes` và `duration` áp dụng cho trung bình trên thang $\ln(1+x)$, không phải chênh lệch byte hoặc giây trung bình trên thang gốc.

Bảng 4.8: Kết quả Welch ANOVA cho bốn câu hỏi nghiên cứu

RQ	Biến phân tích	F	Bậc tự do $(df_1; df_2)$	p thô	p Holm	$\eta^2_{\text{mô tả}}$	$\omega^2_{\text{mô tả}}$
RQ1	`count`	35.907,45	(4; 405,490)	$< 10^{-300}$	$< 10^{-300}$	0,4049	0,4049
RQ2	`serror_rate`	31.976,20	(4; 386,813)	$< 10^{-300}$	$< 10^{-300}$	0,6202	0,6202
RQ3	$\ln(1 + \texttt{src_bytes})$	42.494,96	(4; 387,016)	$< 10^{-300}$	$< 10^{-300}$	0,5639	0,5639
RQ4	$\ln(1 + \texttt{duration})$	1.652,44	(4; 386,205)	$2{,}16 \times 10^{-241}$	$2{,}16 \times 10^{-241}$	0,0412	0,0412

η^2 và ω^2 được tính từ tổng bình phương cổ điển trên thang phân tích, nên là chỉ số mô tả, không phải effect size suy ra trực tiếp từ Welch F. Không dùng các giá trị này để xếp hạng khả năng dự đoán của đặc trưng.

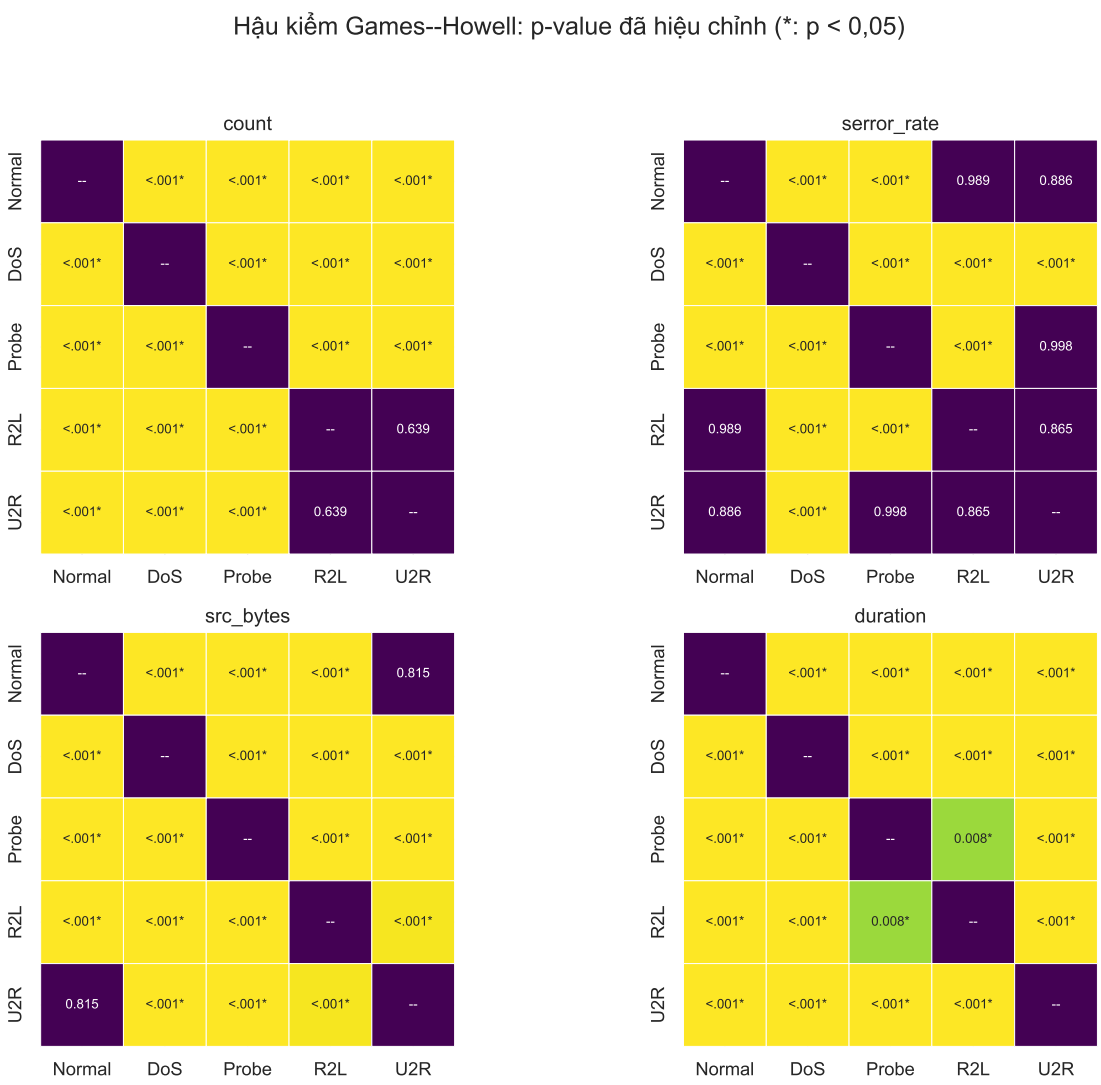
Effect size cho thấy p-value rất nhỏ không đồng nghĩa mức phân tách thực tiễn giống nhau: η^2 mô tả của `serror_rate` là 0,6202, trong khi `duration` chỉ là 0,0412 trên thang phân tích.

4.5.3 Hậu kiểm Games–Howell và trả lời câu hỏi nghiên cứu

Games–Howell kiểm soát so sánh nhiều cặp trong từng RQ và không giả định phương sai hay cỡ mẫu bằng nhau. Bảng 4.9 tóm tắt toàn bộ 10 cặp/RQ; Hình 4.7 trình bày p-value hiệu chỉnh bằng cả số và ký hiệu, nên không cần suy luận chỉ dựa trên màu.

Bảng 4.9: Tóm tắt hậu kiểm Games–Howell trong từng câu hỏi

RQ	Cặp có ý nghĩa	Các cặp chưa đủ bằng chứng khác biệt ở mức 5%
RQ1 – `count`	9/10	R2L–U2R: chênh lệch $-4{,}51$, KTC 95% $[-13{,}71; 4{,}69]$, $p_{adj} = 0{,}639$.
RQ2 – `serror_rate`	6/10	Normal–R2L; Normal–U2R; Probe–U2R; R2L–U2R.
RQ3 – $\ln(1 + \texttt{src_bytes})$	9/10	Normal–U2R: chênh lệch 0,455, KTC 95% $[-0{,}733; 1{,}643]$, $p_{adj} = 0{,}815$.
RQ4 – $\ln(1 + \texttt{duration})$	10/10	Không có; cả 10 khoảng tin cậy đồng thời không chứa 0.



Hình 4.7: P-value Games–Howell đã hiệu chỉnh trong 10 so sánh cặp của từng RQ. Dấu * biểu thị $p_{adj} < 0{,}05$; ô không có dấu * không được diễn giải là hai trung bình bằng nhau, mà chỉ là chưa đủ bằng chứng khác biệt với dữ liệu hiện có.

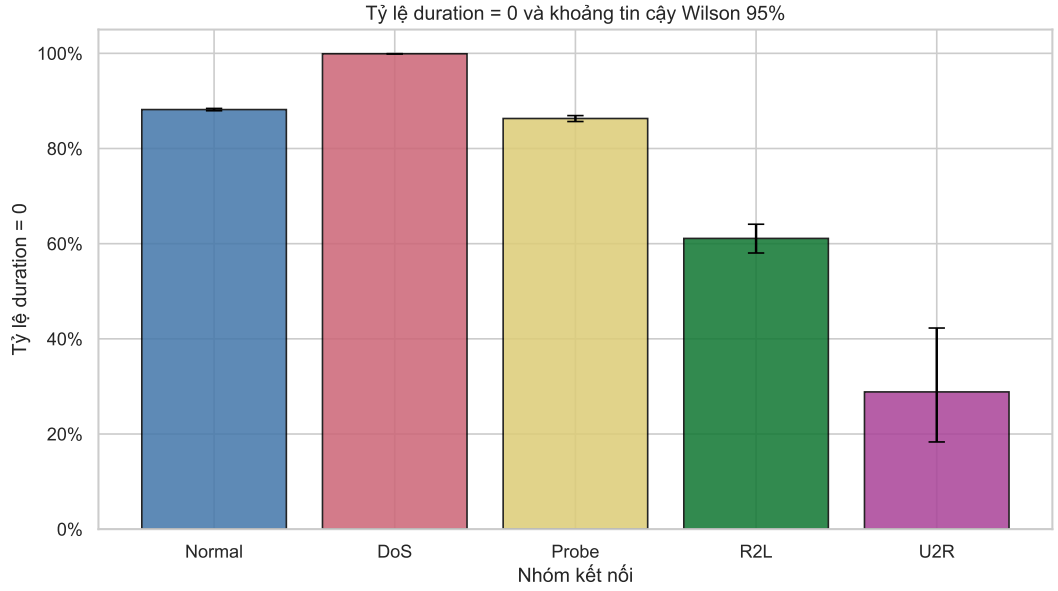
RQ1 – số lượng kết nối gần đây. Trung bình `count` khác nhau giữa ít nhất hai nhóm. DoS cao nhất (178,09), tiếp đến Probe (77,05) và Normal (22,52); R2L và U2R lần lượt là 1,30 và 5,81. Games–Howell cho thấy 9/10 cặp khác biệt, ngoại trừ R2L–U2R. Kết quả ủng hộ nhận định hành vi tạo kết nối trong cửa sổ hai giây khác nhau rõ giữa DoS, Probe và Normal, nhưng không chứng minh mọi dạng tấn công đều có `count` cao.

RQ2 – tỷ lệ lỗi SYN. DoS có trung bình `serror_rate`=0,748 và trung vị 1, vượt xa Normal (trung bình 0,013; trung vị 0). Chênh lệch DoS–Normal là 0,735 với KTC đồng thời 95% $[0{,}729; 0{,}741]$, $p_{adj} < 10^{-300}$. Tuy vậy, chỉ 6/10 cặp có ý nghĩa và phân bố dồn mạnh ở 0 hoặc 1. ANOVA vì thế cung cấp xấp xỉ hữu ích về trung bình tỷ lệ trong mẫu, không phải một mô hình đầy đủ cho biến tỷ lệ bị dồn biên.

RQ3 – lượng byte gửi từ nguồn. Trên thang gốc, Probe và R2L có trung bình rất cao (385.679,84 và 307.727,30 byte) nhưng trung vị chỉ là 1 và 334 byte, cho thấy trung bình

bị chi phối bởi đuôi phải. Welch ANOVA trên $\ln(1+\texttt{src_bytes})$ bác bỏ H_0; 9/10 cặp có ý nghĩa, riêng Normal–U2R chưa đủ bằng chứng. Phát hiện này trả lời câu hỏi về trung bình sau biến đổi log, không được chuyển thành phát biểu rằng một nhóm chênh một số byte trung bình tương ứng.

RQ4 – thời gian kết nối. Welch ANOVA trên $\ln(1+\texttt{duration})$ bác bỏ H_0 và cả 10 cặp Games–Howell có ý nghĩa. Tuy nhiên, trung vị bằng 0 ở bốn nhóm và tỷ lệ bằng 0 thay đổi từ 28,85% đến 99,91% (Hình 4.8), nên kết quả chỉ được xem là bằng chứng tổng hợp trên thang log, không phải một mô hình hoàn chỉnh cho dữ liệu zero-inflated.



Hình 4.8: Tỷ lệ `duration`=0 và khoảng tin cậy Wilson 95% theo nhóm. Đây là phần nhị phân của phân tích hai phần, không phải khoảng tin cậy của thời lượng trung bình.

Trong 10.018 kết nối có $\texttt{duration} > 0$, phân tích bổ sung bằng Welch trên $\ln(1+\texttt{duration})$ vẫn có ý nghĩa, $F(4; 158{,}324) = 315{,}82$, $p = 2{,}48 \times 10^{-74}$. Đây là kết quả có điều kiện và không thay thế kết quả trên toàn bộ mẫu.

Ý nghĩa khoa học. ANOVA cho thấy bốn khía cạnh hành vi mạng có phân bố trung bình khác nhau theo nhóm, nhưng mức chồng lấp, thang đo và độ ổn định của U2R khác nhau đáng kể. Kết quả hỗ trợ diễn giải những tín hiệu mà mô hình học máy có thể khai thác, song p-value nhỏ không đo trực tiếp năng lực dự đoán và không chứng minh quan hệ nhân quả. Do NSL-KDD là bộ chuẩn lịch sử và không có định danh phiên đủ để kiểm chứng độc lập, suy luận chỉ áp dụng cho mẫu đang phân tích; Welch xử lý phương sai không bằng nhau nhưng không khắc phục được phụ thuộc tiềm ẩn giữa các kết nối.

4.6 Kết quả kiểm định Chi-square và mức độ liên hệ

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

4.7 Kết quả huấn luyện và đánh giá hồi quy Logistic

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

4.8 Tổng hợp và đối chiếu các phát hiện

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

4.9 Hạn chế dữ liệu, phương pháp và khả năng khái quát

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

Chương 5

Kết luận và kiến nghị

5.1 Kết luận theo từng câu hỏi nghiên cứu

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

5.2 Kiến nghị và hướng phát triển

[Viết phần này theo quy chuẩn chung; thay dòng hướng dẫn bằng nội dung phân tích đã kiểm chứng.]

Bibliography

[1] M. Tavallaee, E. Bagheri, W. Lu, and A. A. Ghorbani, "A Detailed Analysis of the KDD CUP 99 Data Set," in *2009 IEEE Symposium on Computational Intelligence for Security and Defense Applications*, pp. 1–6, 2009. DOI: 10.1109/CISDA.2009.5356528.

[2] Canadian Institute for Cybersecurity, University of New Brunswick, "ISCX NSL-KDD dataset 2009," 2009. https://www.unb.ca/cic/datasets/nsl.html.

[3] ACM SIGKDD, "KDD Cup 1999: Computer network intrusion detection – Tasks," 1999. https://www.kdd.org/kdd-cup/view/kdd-cup-1999/Tasks.

[4] UCI KDD Archive, "KDD Cup 1999: Training attack types," 1999. https://kdd.ics.uci.edu/databases/kddcup99/training_attack_types.

[5] Y. Imrana, Y. Xiang, L. Ali, Z. Abdul-Rauf, Y.-C. Hu, S. Kadry, and S. Lim, "χ^2-BidLSTM: A Feature Driven Intrusion Detection System Based on χ^2 Statistical Model and Bidirectional LSTM," *Sensors*, vol. 22, no. 5, article 2018, 2022. DOI: 10.3390/s22052018.

[6] MIT Lincoln Laboratory, "1998 DARPA Intrusion Detection Evaluation Dataset," 1998. https://www.ll.mit.edu/r-d/datasets/1998-darpa-intrusion-detection-evaluation-dataset.

[7] UCI KDD Archive, "KDD Cup 1999: Machine-readable data schema," 1999. https://kdd.ics.uci.edu/databases/kddcup99/kddcup.names.

[8] A. M. Al Tobi and I. Duncan, "KDD 1999 generation faults: a review and analysis," *Journal of Cyber Security Technology*, vol. 2, nos. 3–4, pp. 164–200, 2018. DOI: 10.1080/23742917.2018.1518061.

Phụ lục A

Phân công và đóng góp của các thành viên

Điền tên đầy đủ, mã số sinh viên, nhiệm vụ phụ trách và đóng góp thực tế sau khi thống nhất trong nhóm. Không tự động suy diễn đóng góp từ bảng phân công ban đầu.